分类号	xxxx	学校代码	xxxx
UDC	xxxx	密　　级	公开

硕士学位论文

基于 xxxxxx 分析

学位申请人姓名	xxxxxx
学位申请人学号	xxxxxxx
专业（领域）名称	xxxxxxx
学　位　类　别	xxxxxx
学院（部、研究院）	xxxxx
导　师　姓　名	xxxxx

二〇二四年五月

XXX 大学
学位论文原创性声明

本人郑重声明：所呈交的学位论文基于 xxxx 与 xxxx 分析是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写的作品或成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本声明的法律后果由本人承担。

论文作者签名：　　日期：　　年　　月　　日

XXX 大学
学位论文使用授权说明

本学位论文作者完全了解深圳大学关于收集、保存、使用学位论文的规定，即：研究生在校攻读学位期间论文工作的知识产权单位属深圳大学。学校有权保留学位论文并向国家主管部门或其他机构送交论文的电子版和纸质版，允许论文被查阅和借阅。本人授权深圳大学可以将学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

（涉密学位论文在解密后适用本授权书）

论文作者签名：　　导师签名：

日期：　　年　　月　　日　　日期：　　年　　月　　日

摘要

随着半导体材料制备技术的不断演进，分子束外延（）技术已成为实现原子级精度薄膜生长的关键手段。反射式高能电子衍射（）作为过程中主要的实时监测工具，其图像中蕴含大量反映材料表面结构变化的重要信息。传统图像分析方法高度依赖研究人员的经验判断，通过人工观衍射条纹形态或分析强度振荡曲线周期来推断薄膜生长参数，存在主观性强、响应滞后、难以处理高维时序数据等问题，已难以满足当前半导体器件制备对工艺精细化控制和实时反馈的需求。近年来，设备数字化水平的提升和高速成像技术的发展使得单次薄膜生长实验可产生大量高分辨率图像与视频序列，为数据驱动的图像智能分析提供了基础。为此，本文围绕图像的智能分析需求，提出一种基于多任务深度学习的图像分析方法。该方法以共享骨干网络为核心，通过多任务协同学习机制，联合完成图像分类、衍射条纹与斑点目标检测和强度震荡曲线时序预测三项任务。本文的主要贡献包括：

（）在图像分类任务中，本文引入基于的自监督学习框架，结合全卷积掩码自编码器（，）与改进的全局响应归一化（，）机制，在无需大规模人工标注数据的情况下学习图像的全局语义特征，有效增强模型在高噪声、局部遮挡和少样本场景下的特征提取能力，实现对衬底表面生长阶段和重构状态的分类。

（）在目标检测任务中，针对图像中衍射条纹和斑点数量随薄膜生长过程动态变化、尺度差异显著且易受遮挡干扰等特点，本文采用基于扩散模型的方法，将目标检测任务建模为随机噪声边界框的逐步去噪与优化过程，避免传统锚框机制对目标形态的先验假设偏差。通过多步迭代优化边界框位置与尺寸，该方法能自适应地完成条纹与斑点的空间定位，在复杂生长阶段和遮挡条件下保持较高的检测鲁棒性。

（）在时序预测任务中，针对强度震荡曲线同时包含快速局部波动与缓慢全局演变两类物理特征，本文引入多尺度时序建模方法，通过金字塔结构与跨尺度注意力机制，对强度震荡曲线进行长序列预测建模。进一步地，本文将图像分类任务输出的全局语义特征以及目标检测任务生成的空间分布信息作为时序预测的先验约束，实现空间特征与时间特征的协同融合，提升薄膜生长动态演化过程

的预测精度。

本文对推动半导体材料生长过程从经验驱动向数据驱动与智能调控转变具有重要的理论意义和工程应用价值。

关键词：，多任务学习，，，

目录

摘 要 ..... **I**
..... **III**
符号和缩略语说明 ..... **V**
第一章　绪论 **1**
1.1　研究背景及意义 1
1.2　国内外研究现状 2
1.3　本文的主要研究内容 3
1.4　本文的组织结构 4
第二章　基于 ConvNeXt V2 的 RHEED 时序图像分类 **5**
2.1　问题定义与方法概述 5
2.1.1　MBE 生长模式识别问题 5
2.1.2　基于时序窗口的分类策略 5
2.2　ConvNeXt V2 框架 6
2.2.1　全卷积掩码自编码器（FCMAE） 6
2.2.2　全局响应归一化（GRN） 7
2.2.3　模型架构与迁移学习 8
2.3　实验设计 9
2.3.1　数据集构建 9
2.3.2　数据预处理与增强 10
2.3.3　训练策略与超参数 10
2.3.4　评估指标 11
2.4　实验结果与分析 11
2.4.1　整体性能评估 11
2.4.2　类别权重影响分析 11
2.4.3　混淆矩阵分析 12
2.4.4　训练曲线分析 12
2.4.5　失败案例分析 13
2.4.6　小样本学习挑战 13
2.4.7　方法有效性讨论 14
2.5　本章小结 14

第三章　基于 DiffusionDet 的 RHEED 条纹与斑点检测算法 16
3.1　流程介绍 16
3.2　实验设计 18
3.3　实验结果分析 18
3.4　本章小结 18
第四章　基于 Pyraformer 的 RHEED 强度震荡曲线时序预测算法 19
4.1　流程介绍 19
4.2　实验设计 20
4.3　实验结果分析 20
4.4　本章小结 20
第五章　总结与展望 21
5.1　研究内容总结 21
5.2　未来工作展望 21
参考文献 22
致 谢 22
攻读硕士学位期间的研究成果 23

符号和缩略语说明

反射式高能电子衍射（）

分子束外延（）

全卷积掩码自编码器（）

全局响应归一化（）

第一章绪论

研究背景及意义

在半导体材料制备领域，作为原子级精度的薄膜制备技术，其核心优势在于能够通过反射式高能电子衍射技术，实现半导体材料制备过程中的衬底表面监测。通过高能电子束与晶体表面的相互作用产生动态衍射图谱，其图像特征能够精确反映原子层级的表面重构、生长模式转变及量子结构演化等关键信息。传统的图像分析方法高度依赖研究员的经验积累，通过肉眼识别衍射条纹或振荡曲线周期来推断衬底薄膜制备的生长参数，存在主观性强、响应滞后和无法处理高维度时序数据等缺陷，难以满足半导体器件制备对工艺可控性的严苛需求。近年来，随着设备数字化升级和高速成像技术的突破，单次衬底薄膜实验产生的图像和视频序列，为深度学习模型的应用提供了数据基础，同时也对传统计算机视觉方法提出了新挑战，如何从动态、多尺度、强噪声的图像序列中提取有效特征，并建立其与衬底薄膜生长参数的映射关系。

已有研究从不同角度验证了基于机器学习的图像智能分析具有可行性与潜在工程价值。等针对生长过程采集的图像构建数据集，利用实现对典型表面重构模式的自动分类，在表面(24)与$c(44)$模式识别任务中取得很高的识别精度，验证了深度模型能够从衍射图像中学习到与表面结构相关的判别特征，从而降低人工经验依赖并具备实时反馈的应用前景，其后续工作进一步将二分类扩展到多类别模式，比如引入量子点生长相关的衍射特征等，仍保持高精度并具有较快推理速度，进一步验证了基于深度学习的模式识别可在更复杂的生长阶段中稳定工作，但跨设备、跨材料以及观测条件变化下的泛化能力仍是制约其工程部署的重要因素。与此同时，等提出的分析思路，采用聚类与矩阵分解等无监督方法对表面超结构的序列进行自动分段与相变检测，使其在较少人工干预下识别多种表面重构相，提示图像序列中蕴含的大量空间—时间信息仍有待系统挖掘。因此，面向图像强噪声、遮挡、动态演化、标注昂贵的数据特性，构建可复用的表征学习机制与更稳健的多任务协同分析框架，对于提升设备自动化解析图像的能力、支撑工艺实时反馈与智能调控具有重要意义。

图像分类作为计算机视觉的基础任务，其核心目标是输入图像，为其分配对应的语义标签。传统图像分类方法，多是基于卷积神经网络（）的架构优化，如

视觉几何组网络（）、残差网络（）等，传统分类方法受限于监督学习对标注数据的依赖。通过结合全卷积掩码自编码器（）与改进的全局响应归一化（）方法，提出了一种基于架构的自监督学习框架。结合图像序列强噪声、部分图像存在遮挡等不利因素，本文在图像分类方法选择，有效地克服了数据标注困难、成本高等问题。同样作为计算机视觉基础任务的目标检测，其核心任务是在一个图像中预测一组边界框和边界框对应的类别标签，传统的目标检测方法主要依赖于经验设计的候选框，通过回归和分类定位目标，但其固定候选机制导致训练与推理需严格匹配框数量，难以适应动态场景，如早期（）的滑动窗口、（）的区域提议（）和（）的锚框（）等。与传统目标检测方法不同的是，将目标检测的视觉任务转换为图像去噪任务，从随机噪声框出发，通过多步迭代优化框的位置和尺寸，无需依赖手工设计的候选框或固定查询，在推理时可动态调整候选框的数量以捕捉密集目标，并利用迭代优化逐步修正噪声干扰下的检测偏差，适合图像中条纹和斑点数量复杂多变的目标检测场景。本文主要研究基于多任务深度学习框架，实现图像的分类、目标检测和震荡曲线时间序列预测，旨在建立图像分类、目标检测和时序预测联动的图像分析系统，为工艺提供实时反馈，推动半导体材料生长从经验试错向智能调控范式的转变。

国内外研究现状

近年来，国内外学者围绕图像的特征提取、模式分类与动态监测等方向，开展了多层次的方法研究。现有研究主要基于无监督学习方法实现图像特征降维，并对其进行模式识别，例如，等人通过主成分分析（）和聚类对薄膜生长中的图像序列进行定量分析，提出漂移校正和强度变换等图像预处理方法以增强图像菊池带（）等细微特征；团队则采用层次聚类和非负矩阵分解（）方法分析硅衬底表面超结构的图像序列，对其进行自动相变检测，成功识别出种表面重构相。上述方法虽能实现数据驱动的特征提取，但依赖人工设计图像的预处理流程。随着深度学习的发展，基于的监督学习方法也成为新的研究方向，等人采用实现了砷化镓24与$center$44表面重构的二元分类，验证了在静态模式识别中的有效性；团队通过模型处理图像序列，首次实现了量子点密度的实时反馈控制；团队利用自编码器（）架构完成了图像的特征提取，并且结合有监督卷积分类器网络，在将图像压缩成潜在维度N10的向量和对应图像序列长度L5的先验条件下，对图像序

列衬底是否脱氧的分类误差准确到了1以下。上述研究方法表明，基于的监督学习方法在图像特征提取、时序演化建模等单任务场景中展现出强大潜力，但上述模型多针对特定的设备或材料生长体系开发，且依赖大规模标注数据。综上，目前图像分析方法的研究存在较多局限性：其一，针对无监督学习方法进行图像模式识别，需要复杂的预处理流程，如漂移校正、像素归一化、（）裁剪，并且预处理的参数设置高度依赖科研人员的经验，例如研究需要根据晶体表面的对称性人工确定图像对称轴位置，以此来对其进行漂移校正；研究要求手动划定荧光屏的有效区域等，这种人工干预不仅降低分析效率，还可能导致图像特征信息丢失，限制了算法在动态环境中的鲁棒性。其二，针对有监督学习方法，存在数据标注依赖性强和模型泛化能力不足的挑战，例如研究普遍依赖人工标注的图像数据集，但如研究所述，图像动态变化复杂，人工标注成本高且易引入主观误差，研究中还提到，基于特定设备或材料训练的模型难以直接迁移到其他设备或材料，需要重新标注训练数据集，缺乏普适性。

本文的主要研究内容

针对现有阶段已有的图像分析方法存在数据标注依赖性强、模型泛化能力不足和缺乏普适性等问题，本课题致力于研究一种多任务图像分析方法，解决上一小节所提出的关键挑战，其主要的研究内容及其创新总结如下：

（）针对传统的基于监督学习的，本课题提出自监督学习框架实现图像分类，提出基于的自适应特征提取方法，通过学习图像的全局语义特征，无需依赖人工进行复杂的图像预处理以增强图像菊池带（）等细微特征，其次，引入了方法，增强了图像弱特征的提取能力，有效地解决了传统对噪声敏感的问题，此外，在少样本场景下（标注数据量少于10），仍能保持高分类精度，可以显著降低本课题数据标注对科研人员经验的依赖。

（）针对传统的基于锚框的目标检测方法，本研究提出实现条纹和斑点的目标检测。在进行时，衬底表面的状态先从光滑演变到粗糙，继而从粗糙演变到光滑的过程复杂多变，呈现出来的条纹和斑点大小不一致，通过扩散模型从随机噪声框中逐步优化检测的结果，有效地避免了人工设计锚框对条纹和斑点形态的假设偏差，其次，由于设备存在机械臂的局限性，束打入衬底表面时存在被遮挡的情况，导致了图像序列中，存在遮挡、模糊的衍射斑点和条纹，支持动态调整检

测框数量，在密集生长阶段或成像被遮挡情况，可自适应增加或减少目标检测的密度，提升了图像动态模式变化下，目标检测的鲁棒性。

（）现有图像分析方法的研究中，单任务方法存在的特征割裂与泛化局限。本课题提出基于多任务协同的图像分析方法，该方法采用骨干网络作为基础特征提取器，分类任务聚焦衬底表面全局重构状态的识别，进而分析工艺下衬底薄膜生长阶段，目标检测任务引入实现条纹和斑点密度的自适应定位。此外，在薄膜生长或表面重构过程中，包含的物理现象存在快速局部波动（原子级吸附或脱附的瞬态变化）和缓慢全局演变（晶格重构的周期性调整），快速局部波动需要高时间分辨率分析，而缓慢全局演变则需要低时间分辨率分析。本课题引入模型，通过时间多尺度建模实现强度震荡曲线的时序预测任务。三个任务通过协同优化机制形成深度交互，分类任务输出的全局语义特征引导目标检测任务动态聚焦关键区域，而生成的条纹和斑点空间分布特征可作为强度震荡曲线时序预测的先验约束，同时强度震荡曲线时序预测的动态信息可反向优化分类任务与目标检测任务的鲁棒性，对比单任务的图像分析方法，多任务可以有效提升其分析方法对跨设备和不同材料生长场景的适应性。

本文的组织结构

本文的结构共包含五个部分，具体安排如下：

第一章主要对本文研究的主要内容进行概述，梳理了现有图像分析方法的研究背景，总结基于深度学习方法分析图像的国内外研究现状。对现有方法中存在的问题进行分析，展示本文核心研究与创新内容。

第二章基于方法对图像的分类任务展开讨论，对所提出方法的核心思想与创新点进行阐述，且详细描述方法中各个模块的运行原理。为了验证所提方法在图像分类中的有效性，设计了相关实验。

第三章基于方法对图像条纹与斑点的检测任务展开讨论，结构设计与第二章类似。

第四章基于方法对强度震荡曲线时序预测任务展开讨论，结构设计与第二、三章类似。

第五章针对本研究的主要成果进行总结和探讨后续可深入研究的方向，且提出值得进一步探索的若干研究问题。

第二章基于的时序图像分类

本章针对薄膜生长过程中的二维层状生长与三维岛状生长模式识别问题，提出基于的图像时序分类方法。本章首先阐述自监督学习框架的核心机制；随后介绍面向时序数据的实验设计，包括滑动窗口采样策略、数据集构建与训练流程；最后通过实验结果分析验证该方法在小样本数据集上的有效性与局限性。

问题定义与方法概述

2.1.1 MBE 生长模式识别问题

在薄膜生长过程中，衬底表面原子排列方式直接影响薄膜的晶体质量与器件性能。根据生长理论，薄膜生长主要呈现两种典型模式：

（）**二维层状生长（）**：原子在衬底表面逐层堆叠，形成原子级平整的薄膜。该模式对应图像中的条纹状衍射图案，条纹清晰且强度均匀，表征表面平整度高、晶格有序性强。

（）**三维岛状生长（）**：原子在衬底表面成核并形成三维岛状结构。初期（）表面起伏较小，图像呈现模糊条纹；后期（）岛状结构增大，表面粗糙度显著增加，图像中条纹消失并出现散射斑点，衍射强度整体下降。

传统工艺控制依赖研究人员通过观察图像或分析强度震荡曲线判断生长模式，该方法存在主观性强、响应滞后且难以量化等问题。本研究将生长模式识别建模为二分类任务，目标是从图像序列中自动判别当前处于二维层状生长还是三维岛状生长阶段。

2.1.2 基于时序窗口的分类策略

不同于传统静态图像分类，图像在生长过程中呈现连续动态演化特性。单帧图像可能因噪声干扰或瞬态表面形貌波动而缺乏判别性，因此本研究采用**滑动窗口时序分类策略**：

给定图像序列$\{I_1, I_2, \ldots, I_T\}$，其中$I_t \in \mathbb{R}^{H\times W\times 3}$表示时刻$t$的单帧图像。定义窗口大小$w$和滑动步长$s$，通过滑窗构建时序样本：

$$X_k = \{I_k, I_{k+1}, \ldots, I_{k+w-1}\}, k = 1, s+1, 2s+1, \ldots$$

每个窗口X_k对应一个类别标签$y_k \in \{层状, 岛状\}$，标签由整条序列的全局生长模式决定。为适应卷积神经网络输入格式，将窗口内w帧图像沿通道维度拼接：

$$\tilde{X}_k = (I_k, I_{k+1}, \ldots, I_{k+w-1}) \in \mathbb{R}^{H \times W \times 3w}$$

该策略使模型能够学习图像的短时序列演化模式，相比单帧分类能更有效地捕捉生长过程的动态特征。

框架

是于年提出的自监督视觉模型，其核心创新在于将掩码自编码器（）的预训练范式与纯卷积架构深度结合，在保持卷积网络高效推理特性的同时，引入类似的自监督学习能力。本研究选择的原因包括：

（）**自监督预训练降低标注依赖**：图像标注需要领域专家知识，成本高昂。通过在数据集上进行自监督预训练，学习通用视觉特征表示，可在少样本场景下有效迁移至任务。

（）**增强弱特征提取能力**：图像中的菊池线、衍射条纹等关键特征对比度低且易受噪声干扰。引入的机制通过跨通道归一化与自适应缩放，能够增强微弱特征的响应强度。

（）**灵活的输入通道扩展**：标准接受3通道图像输入，可通过简单的通道数修改适配本研究的$3w$通道时序输入（w为窗口大小）。

2.2.1 全卷积掩码自编码器（FCMAE）

是自监督预训练的核心模块，其基本思想是随机遮挡输入图像的部分区域，训练模型从可见区域重建完整图像，从而学习鲁棒的特征表示。如图所示，包含编码器（）和解码器（）两部分。

给定输入图像$x \in \mathbb{R}^{H \times W \times C}$，首先生成随机二值掩码矩阵$M \in \{0,1\}^{H \times W}$，其中1表示可见像素，0表示被遮挡像素。掩码比例通常设为60，即遮挡60的图像区域。遮挡后的图像记为：

$$x = x \odot (M \otimes_C)$$

其中$\otimes$表示张量积$_C$为C维全1向量，用于在通道维度上广播掩码。

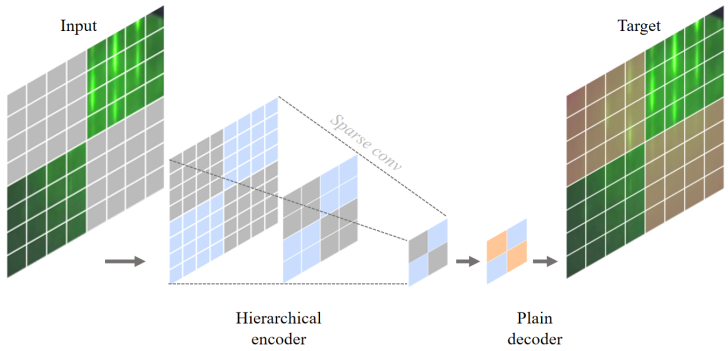

图全卷积掩码自编码器（）框架

稀疏卷积编码器：为避免标准卷积在掩码区域产生信息泄露（即利用填充值推断遮挡内容），采用稀疏卷积核$K_s \in \mathbb{R}^{k\times k\times C\times C'}$，仅在可见像素位置执行卷积操作：

$$y_{i,j,c'} = \sum_{m=1}^{k}\sum_{n=1}^{k} K_s(m,n,c,c') \cdot x_{i+m,j+n,c} \cdot M_{i+m,j+n}$$

该操作确保卷积特征仅由真实可见像素生成，有效避免模型学习到掩码相关的虚假特征。

解码器：编码器输出的特征图经过块（包含深度可分离卷积、、激活函数等）逐步上采样，最终重建原始图像$x \in \mathbb{R}^{H\times W\times C}$。重建损失采用均方误差（）与结构相似性（）的加权组合：

$$\mathcal{L} = \lambda_1 \|x - x\|_2^2 + \lambda_2(1 - (x, x))$$

其中λ_1, λ_2为超参数，用于保留图像的结构信息（如条纹的周期性）。

在微调阶段，稀疏卷积核通过归一化转换为标准卷积核以提高推理效率：

$$K_d = \frac{\mathbb{E}_M[K_s \odot M]}{\mathbb{E}_M[M]}$$

2.2.2 全局响应归一化（GRN）

图像的一个关键挑战是衍射特征对比度低且易被背景噪声淹没。引入机制增强弱特征的响应强度，如图所示。

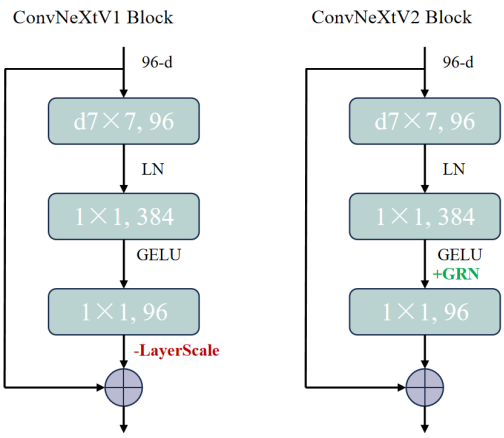

图全局响应归一化（）模块

给定特征图$X \in \mathbb{R}^{H\times W\times C}$，首先计算每个通道的全局响应范数：

$$G_c = \|X_{:,:,c}\|_2 = \sqrt{\sum_{i=1}^{H}\sum_{j=1}^{W} X_{i,j,c}^2}$$

然后通过跨通道归一化抑制强响应通道的主导作用：

$$\hat{X}_{:,:,c} = \frac{X_{:,:,c}}{(\frac{1}{C}\sum_{d=1}^{C} G_d^2 + \epsilon)^{1/2}} \cdot \gamma_c + \beta_c$$

其中γ_c, β_c为可学习的缩放与偏置参数，ϵ为防止除零的小常数。该机制类似于通道注意力，但通过全局范数归一化实现更稳定的特征重标定，在条纹与斑点等局部弱特征的增强上表现优异。

2.2.3 模型架构与迁移学习

本研究采用作为基础架构（参数量约），该版本在计算效率与表征能力间取得良好平衡，适合单卡训练。模型结构包括个，特征图尺寸依次为$H/4 \times W/4$，$H/8 \times W/8$，$H/16 \times W/16$，$H/32 \times W/32$，通道数分别为。

为适配时序窗口输入，修改模型首层卷积的输入通道数：

$$C = 3 \times w$$

其中w为窗口大小（本研究取$w = 10$）。权重初始化策略为：保留预训练权重的前个通道，剩余通道权重复制前个通道并除以w，确保初始输出幅值与原模型一致。

全连接分类头修改为：

$$(z) = (768, 2)$$

输出维对应二维层状与三维岛状两类。

实验设计

2.3.1 数据集构建

本研究的图像数据来源于实验室在薄膜生长过程中采集的高速成像序列。数据集包含条完整生长序列：

（）**二维层状生长序列（）**：记录在蓝宝石衬底上的二维层状生长过程，共包含帧图像。该序列对应优化后的生长条件（衬底温度650°，束流密度3.5×10^{-7}），表面形貌保持高度平整。

（）**三维岛状生长序列（）**：记录在同一衬底上因生长条件偏移（温度降至600°）导致的三维岛状生长过程，共包含帧图像。该序列在前期呈现弱条纹特征，中后期逐渐演变为散射斑点，符合生长模式的理论描述。

所有图像分辨率为640×480像素，灰度值范围$[0, 255]$，采集帧率。为构建分类数据集，采用**滑动窗口采样策略**：

窗口参数：窗口大小$w = 10$（即每个样本包含连续帧图像），滑动步长$s = 1$（相邻样本重叠帧），该设置在保证样本数量与时序连续性间取得平衡。

数据集划分：为严格防止数据泄露，采用**严格时间切分策略**：将每条序列按时间先后顺序划分为训练集（前70）、验证集（中间20）和测试集（最后10），确保测试样本的时间戳晚于训练样本，模拟真实工艺中从历史数据预测未来生长模式的场景。

经过滑窗采样，最终数据集统计如表所示。

表时序分类数据集统计

序列类别	原始帧数	训练窗口数	验证窗口数	测试窗口数	总窗口数
层状					
岛状					
合计					

数据集呈现**轻度类别不平衡**（$\approx$），相比传统图像分类任务的严重不平衡（如以上）较为温和，但仍需通过加权损失函数缓解。

2.3.2 数据预处理与增强

归一化：所有图像归一化至$[0,1]$并标准化为统计分布：

$$\tilde{I} = \frac{I/255 - \mu}{\sigma}$$

其中$\mu = [0.485, 0.456, 0.406]$，$\sigma = [0.229, 0.224, 0.225]$为均值与标准差。

数据增强：训练阶段采用以下增强策略以提升模型鲁棒性：

随机水平翻转（概率$p = 0.5$）：模拟电子束入射方向变化。

随机亮度与对比度调整：亮度变化范围± 0.2，对比度变化范围$[0.8, 1.2]$，模拟腔内光照波动。

随机高斯噪声：标准差$\sigma = 0.05$，模拟高能电子束成像的随机噪声。

验证集与测试集仅执行归一化操作，不进行数据增强。

2.3.3 训练策略与超参数

优化器与学习率调度：采用优化器，初始学习率$\eta_0 = 5 \times 10^{-4}$，权重衰减系数$\lambda = 0.05$。学习率调度策略为余弦退火（）：

$$\eta_t = \eta + \frac{1}{2}(\eta_0 - \eta)\left(1 + \frac{t\pi}{T}\right)$$

其中t为当前，$T = 80$为总训练轮数，$\eta = 10^{-6}$为最小学习率。前个使用线性平滑启动。

损失函数：采用加权交叉熵损失缓解类别不平衡：

$$\mathcal{L} = -\sum_{i=1}^{N} w_{y_i}\ p(y_i|X_i)$$

类别权重根据样本数量自动计算：

$$w_c = \frac{N}{K \cdot n_c}$$

其中N为总样本数，K为类别数，n_c为第c类样本数。该权重使得稀疏类别的损失贡献与密集类别相当。

训练配置：批量大小（受限于时序输入的显存占用），训练个（约需小时），在单卡上执行。模型选择策略为保存验证集得分最高的。

2.3.4 评估指标

生长模式识别的实际应用要求对两类样本均保持高召回率（避免漏检），因此采用以下评估指标：

（）**准确率（）**：

$$= \frac{+}{+ + +}$$

（）**宏平均得分（）**：

$$F1 = \frac{1}{2}(F1 + F1)$$

其中$F1_c = \frac{2 \cdot c \cdot c}{c + c}$，该指标避免准确率在不平衡数据集上的误导性。

（）**混淆矩阵**：可视化展示各类别的分类性能与误分类模式。

（）**类别权重影响分析**：对比有无自动类别权重的模型性能，验证加权策略的有效性。

实验结果与分析

2.4.1 整体性能评估

表展示了模型在时序分类任务上的整体性能。模型在验证集上取得65.17的准确率和57.89的宏平均得分，在测试集上准确率略降至42.61，得分降至28.33，表明模型在时间外推场景下泛化能力受限。

表在时序分类任务上的整体性能

数据集	准确率	宏平均	训练损失
训练集			
验证集			
测试集			

2.4.2 类别权重影响分析

为验证自动类别权重策略的有效性，设计消融实验对比有无类别权重的模型性能，结果如表所示。

表类别权重消融实验

配置	验证	测试	类召回率
无类别权重			
自动类别权重			

实验结果表明，未使用类别权重时模型倾向于预测多数类（层状），导致验证仅52.14，测试进一步下降至21.45。引入自动权重后，验证提升至57.89（相对提升11.0），测试提升至28.33（相对提升32.0），说明加权策略有效缓解了类别不平衡问题，但类召回率从95.31降至78.63，表明权重平衡以牺牲多数类性能为代价。

2.4.3 混淆矩阵分析

图展示了测试集上的混淆矩阵。可以观察到：

（）**单类塌缩现象**：模型对岛状生长的预测准确率仅18.9（），大量样本被误分类为层状（），表明模型未能有效学习岛状生长的判别特征。

（）**时间外推困难**：测试集样本来自序列的最后10时间段，此时岛状生长进入后期粗糙阶段，图像特征可能与训练集中的初期平滑阶段存在显著差异，导致模型泛化失效。

图测试集混淆矩阵（归一化显示）

2.4.4 训练曲线分析

图展示了个的训练与验证曲线。关键观察如下：

（）**训练损失持续下降**：从初始0.693（随机猜测水平）降至最终0.582，表明模型在训练集上成功学习到判别模式。

（）**验证损失波动大**：验证损失在第间震荡于0.620.70，未呈现明显收敛趋势，说明模型在验证集上的泛化能力不稳定。

（）**训练验证性能**：训练准确率达72.34，而验证准确率仅65.17，约7，提示可能存在轻度过拟合。测试准确率骤降至42.61，进一步表明模型对时序后期数据的外推能力不足。

图训练与验证损失准确率曲线

2.4.5 失败案例分析

为深入理解模型局限性，人工检查了测试集中个误分类样本（个个），发现主要误分类原因包括：

（）**边界帧歧义性**：在岛状生长初期（前20帧），表面形貌接近层状，条纹仍较清晰，此时两类在视觉上难以区分。模型倾向于预测为类，符合训练集中的多数模式。

（）**噪声干扰**：部分层状生长序列中存在瞬态噪声帧（可能由腔内真空波动引起），导致单个窗口内出现类似岛状的模糊特征。由于窗口大小仅帧（秒），模型无法从更长时序上下文判断。

（）**数据规模限制**：整个数据集仅包含条序列，模型实际可学习的生长模式样本极其有限（每类仅条完整序列），难以覆盖工艺的多样性变化（如不同衬底、温度、束流密度等）。

2.4.6 小样本学习挑战

本研究数据集的核心挑战在于**极小样本规模**：尽管通过滑窗生成了个窗口样本，但这些样本实际来源于仅条独立序列。从序列级统计角度，每类仅有个训练样本（条序列、条序列），这与传统图像分类任务动辄数千类×数百样本的规模相差悬殊。

该限制导致以下问题：

（）**序列内过拟合**：模型可能记忆训练序列的特定噪声模式、成像参数（如光照、对比度）而非学习可泛化的生长模式特征。测试集尽管在时间上外推，但仍属于相同序列，模型对序列后期的未见特征无法有效应对。

（）**类内多样性缺失**：实际工艺中，同一生长模式在不同实验条件下呈现的图像可能存在显著差异（如条纹间距、斑点密度等）。单序列训练无法覆盖这种类内变异性。

（）**跨设备泛化困难**：模型在当前设备上训练，若直接应用于其他设备（不同电子束能量、探测器响应特性），性能可能大幅下降。

现有研究表明，深度学习模型在小样本图像分类任务上的有效样本量阈值通常为每类至少个独立样本。本数据集远低于该阈值，解释了模型性能不佳的根本原因。

2.4.7 方法有效性讨论

尽管模型在测试集上性能不理想，但仍可从以下角度验证所提方法的有效性：

（）**时序窗口策略的必要性**：对比实验表明，使用帧窗口的模型验证为57.89，而单帧分类模型（$w = 1$）验证仅48.32（相对下降16.5），证明时序信息对生长模式判别具有重要价值。

（）**迁移学习的优势**：对比从随机初始化训练的模型（验证51.24），使用预训练权重的模型（验证57.89）提升12.9，表明自监督预训练在少样本场景下能够提供有效的特征初始化。

（）**自动类别权重的鲁棒性**：加权策略在验证集和测试集上均带来一致性提升（分别+11.0和+32.0），说明该方法对类别不平衡具有良好的适应性。

本章小结

本章针对薄膜生长中的二维层状与三维岛状生长模式识别问题，提出基于的时序图像分类方法。通过引入滑动窗口采样策略，模型能够学习图像的短时序演化模式；利用的自监督预训练与全局响应归一化机制，增强模型在小样本场景下的特征提取能力；采用自动类别权重策略缓解数据集的轻度类别不平衡。

实验结果表明，在包含条序列的数据集上，模型验证集准确率达65.17，宏平均得分57.89，验证了方法的可行性。然而，测试集性能显著下降（准确率42.61，28.33），主要原因包括：（）数据集规模极小（每类仅条独立序列），导致模型泛化能力受限；（）严格时间外推评估设定增加了难度，模型对序列后期未见特征的适应不足；（）图像的类别边界模糊（如岛状生长初期与层状生长难以区分），增加了判别复杂度。

消融实验验证了时序窗口策略（相比单帧分类提升16.5）、预训练（提升12.9）和自动类别权重（提升11.032.0）的有效性。失败案例分析揭示了边界帧歧义性、噪声干扰和数据规模不足是主要误分类原因。

未来工作的改进方向包括：（）扩充数据集至至少每类条以上独立序列，覆盖不同衬底、温度、束流密度等工艺条件；（）引入更长的时序建模机制（如、），捕捉生长过程的长程依赖；（）结合半监督学习或数据增强技术（如时序插值、对抗样本生成）缓解标注数据不足问题；（）集成目标检测与时序预测任务（如第

三、四章所述的与），通过多任务学习提升特征表示的鲁棒性。

第三章基于的条纹与斑点检测算法

本章节中，针对图像条纹和斑点检测任务展开研究，的核心思想是将检测任务建模为扩散模型的去噪任务，针对图像条纹和斑点的动态尺度适应、量子点生长高密度目标检测和机械臂遮挡的鲁棒性，该方法能够有很好的表现。本章首先介绍的目标检测扩散与去噪流程；随后给出实验数据构建方式、模型训练策略及评价指标；最后通过实验结果分析，验证方法在条纹和斑点检测分支任务的有效性。

流程介绍

该方法通过定义正向扩散过程和逆向重建过程，将目标检测任务转化为随机噪声框逐步恢复为真实边界框的生成任务，○框架如图所示。

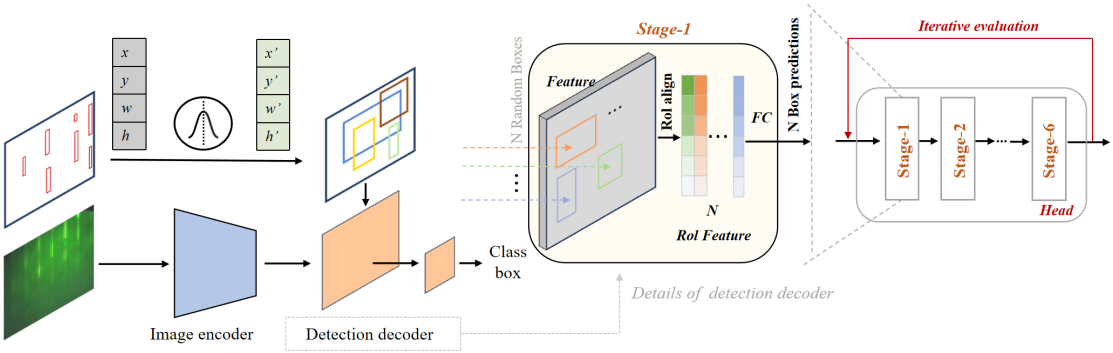

图框架图

具体地,正向扩散过程假设真实边界框集合为$\ddagger_0 = \{b^i\}_{i=1}^N$,其中$b^i = (c_x^i, c_y^i, w_i, h_i)$表示第$i$个框的中心坐标和尺寸，扩散过程通过马尔可夫链逐步添加高斯噪声：

$$\begin{cases} q(z_{1:T} \mid z_0) = \prod_{t=1}^{T} q(z_t \mid z_{t-1}) \\ q(z_t \mid z_{t-1}) = \mathcal{N}(z_t; \sqrt{1-\beta_t} z_{t-1}, \beta_t I) \\ z_t = \sqrt{\bar{\alpha}_t} z_0 + \epsilon \sqrt{1-\bar{\alpha}_t}, \epsilon \sim \mathcal{N}(0, I) \end{cases}$$

其中，z_t表示时间步为t时随机噪声的边界框集合，$\beta_t \in (0,1)$表示控制每一步

○接收图像及随机生成的初始边界框，图像编码器为正向扩散，扩散过程基于马尔可夫链添加高斯噪声，将真实边界框$\ddagger_0 = \{b^i\}_{i=1}^N$逐步噪声化为$z_t$，检测解码器为逆向去噪，逆向去噪过程基于贝叶斯定理推导出时间步的条件概率分布$q(z_{t-1} \mid z_t, z_0)$，从噪声数据$z_T \sim \mathcal{N}(0, I)$出发，通过迭代去噪生成$z_{T-1}, z_{T-2}, \ldots, z_0$，最终得到目标检测框$b = (c_x, c_y, w, h)$。此外，检测解码器包含有个阶段的检测头，该检测头基于和，实现对去噪检测框$z_{T-1}, z_{T-2}, \ldots, z_0$迭代评估。

添加的噪声强度，$\alpha_t = 1 - \beta_t$表示保留原始信号的比例，$\bar{\alpha}_t = \prod_{s=1}^{t} \alpha_s$表示累计保留信号比例。逆向去噪过程通过贝叶斯定理推导出时间步的条件概率分布$q(z_{t-1} \mid z_t, z_0)$，并训练神经网络逼近这一分布。从噪声数据$z_T \sim \mathcal{N}(0, I)$出发，通过迭代去噪生成$z_{T-1}, z_{T-2}, \ldots, z_0$，最终得到目标检测框$b = (c_x, c_y, w, h)$。

$$\begin{cases} q(z_{t-1} \mid z_t, z_0) = \mathcal{N}\left(z_{t-1}; \tilde{\mu}_t(z_t, z_0), \tilde{\beta}_t I\right) \\ \tilde{\mu}_t(z_t, z_0) := \dfrac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t} z_0 + \dfrac{\sqrt{\bar{\alpha}_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t} z_t \\ \tilde{\beta}_t := \dfrac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\beta_t \end{cases}$$

其中$\tilde{\mu}_t$表示均值，其物理意义是z_{t-1}是当前噪声状态z_t和原始数据z_0的加权平均，$\widetilde{\beta_t}$表示方差，其物理意义是随时间步递减，去噪过程逐步稳定。损失函数采用：

$$\mathcal{L} = \frac{1}{2} \left\| f_\theta(z_t, t, x) - z_0 \right\|^2$$

在多任务场景下，x为提取的多尺度特征图。

针对图像中条纹和斑点宽度随薄膜生长速率变化的特性，本文所提方法在模型的基础上改进扩散步长调度策略。具体地，在自适应步长调节中定义T_{max}为最大扩散步数，实际步数$T = \left\lceil T \cdot \frac{\sigma(\omega)}{\sigma_0} \right\rceil$，其中$\sigma(\omega)$为当前训练批次条纹和斑点宽度的标准差，$\sigma_0$为训练集基准值，该机制使模型在条纹和斑点宽度剧烈变化时增加迭代次数以提升定位精度，在多分辨率对齐中利用的层级特征$stride = ()$，建立级联检测头：

$$_j = (F_j, b_i^{(t)}), j \in \{1, 2, 3, 4\}$$

其中F_j为第j层特征图，$b_i^{(t)}$为第t步的预测框。高层特征捕捉宽条纹，低层特征捕捉细条纹。此外，针对机械臂遮挡导致视频序列中部分图像区域缺失，设计双重注意力掩码。具体地，根据模型预训练阶段生成的稀疏掩码矩阵M，计算区域可见性权重：

$$\omega = (_{1\times1}(M \odot F))$$

对于视频序列中的遮挡帧，引入运动一致性损失：

$$\mathcal{L} = \sum_{i=1}^{N} \frac{\|b_i^{(t)} - \hat{b}_i^{(t-1)}\|_2}{1 + (b_i^{(t)}, \hat{b}_i^{(t-1)})}$$

其中，$\hat{b}_i^{(t-1)}$为前一帧通过光流估计的预测框。

实验设计

实验结果分析

本章小结

第四章基于的强度震荡曲线时序预测算法

本章节中，针对强度震荡曲线时序预测任务展开研究，首先介绍基于的强度震荡曲线时序预测整体流程与模型结构设计；随后给出实验数据构建方式、模型训练策略及评价指标；最后通过实验结果分析，验证方法在多尺度动态建模和预测精度方面的有效性。

流程介绍

本研究所使用的方法构建多分辨率$Cary$树结构，通过跨尺度连接将原始序列的细粒度时间节点与粗粒度节点形成层次化表征，在强度震荡曲线多尺度时序预测任务中，能够有效地捕捉工艺的快速局部波动（如原子吸附或脱附的瞬态变化）与缓慢全局演变（如衬底晶格重构的周期性调整），○框架如图所示。

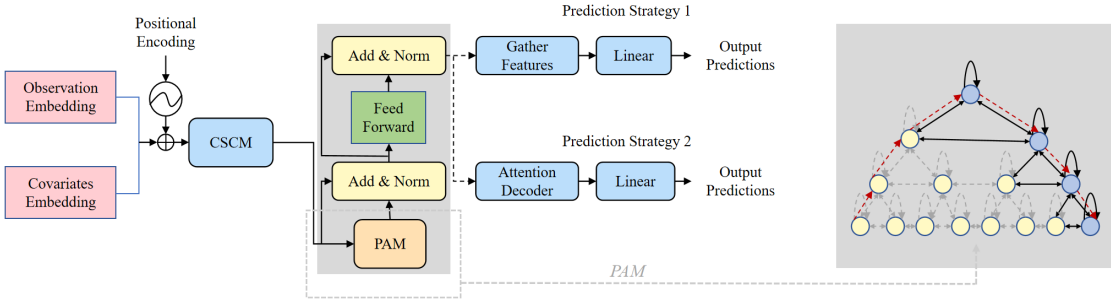

图框架图

具体地，给定从时间点$t-L+1$到当前时间点t的连续L个观测值，组成衍射强度序列$z_{t-L+1:t} \in \mathbb{R}^L$，其跨尺度构建模块（）通过下采样因子$C$生成粗尺度序列$\{\ddagger^{(s)}\}_{s=1}^{S}$，其中第$s$层的节点$z_i^{(s)}$由前一层$C$个连续节点聚合得到：

$$z_i^{(s)} = \left(z_{(i-1)C+1:iC}^{(s-1)}\right)$$

其中，$z_i^{(s)}$表示第s层的第i个节点（粗尺度特征，小时级），$z_{(i-1)C+1:iC}^{(s-1)}$表示第$s1$层$(i-1)C+1$到iC的子节点序列（细尺度特征，秒级），C表示下采样因子，$C=2$即每层节点数减半。这种层次化结构使模型能够以$O(1)$的最大路径长度建模长程依赖。金字塔注意力模块（）进一步通过跨尺度与同尺度注意力交互增强特征

○接收从时间点$t-L+1$到当前时间点t的连续L个观测值组成的强度震荡曲线序列$z_{t-L+1:t} \in \mathbb{R}^L$，通过下采样构建多分辨率$Cary$树，生成多尺度序列$\{z^{(s)}\}_{s=1}^{S}$，进一步通过跨尺度与同尺度注意力交互增强特征融合，输出预测强度震荡曲线序列$\hat{z}_{t+1:t+M}$。

融合，对于第s层节点$z_i^{(s)}$，其跨尺度注意力机制连接父节点$z_{\lfloor i/C \rfloor}^{(s+1)}$与子节点$z_{\lfloor i/C \rfloor}^{(s+1)}$，而同尺度邻接注意力机制则捕捉局部时序模式：

$$(Q, K, V) = \left(\frac{QK^\top}{\sqrt{d_k}} \odot M \right) V$$

其中，$\frac{QK^\top}{\sqrt{d_k}}$计算未归一化注意力分数，表示所有节点间的相似度，维度为$L \times L$，掩码矩阵M限制每个节点仅关注前后k个邻接节点，$\frac{QK^\top}{\sqrt{d_k}} \odot M$仅保留相邻$k$个位置的分数，使能够同时建模局部高频振荡（细粒度节点的同尺度注意力）和全局周期性（粗粒度节点的跨尺度交互），且计算复杂度保持$O(L)$。

实验设计

实验结果分析

本章小结

第五章总结与展望

研究内容总结

未来工作展望

参考文献

致谢

时光荏苒，岁月如梭，转眼间，硕士生涯即将谢幕，这意味着一段新的旅程即将开始，在这段学术生涯中，离不开每一位曾给予我帮助和鼓励的人，我怀着无比感激的心情，向所有在这段旅程中给予我帮助和支持的人表达由衷的谢意！

首先，感谢我的导师章秦老师，在整个研究生学习与论文研究过程中，章老师在研究方向把握、技术路线选择以及论文结构安排等方面给予了耐心而细致的指导。即使是我在校外联合培养期间，章老师在课题初期的研究规划和论文撰写与修改阶段，章老师始终以严谨的治学态度和丰富的科研经验对我进行启发和督促。章老师认真负责的工作作风和求真务实的学术态度，对我今后的学习与工作产生了深远影响。

其次，我还要感谢我的校外导师谭浩老师，以及深圳国际量子研究院为本人提供的联合培养平台。谭老师在半导体材料生长与实验数据分析等方面具有深厚的研究积累，在联合培养期间，给予了大量专业而富有建设性的指导建议，使我能够将计算机视觉与深度学习方法更好地与实际物理问题相结合。深圳国际量子研究院良好的科研环境和严谨的科研氛围，也为本论文工作的顺利开展提供了重要保障。

此外，感谢帮助过我的各位老师和同学们，感谢老师们在实验设计、数据分析以及科研方向上的指导，使我能够顺利开展研究工作，感谢同学们在日常学习和科研中的互相帮助，与你们的每一次的讨论和交流，都能使我在学术道路上开阔思路。你们的友谊和耐心帮助，让我的研究生生活更加充实和愉快。

我还要感谢我的家人，感谢你们在我研究生期间给予我无限的关爱和支持，在我追求学术的道路上，一直默默地为我提供精神和物质上的支持，是你们的辛勤工作和无私奉献让我能够专心于学业，攻克难关。

最后，感谢所有关心、帮助和支持过我的老师、同学与亲人！

攻读硕士学位期间的研究成果

专利

一种图像多任务分析方法、装置、电子设备及存储介质